

끈기로 AI 기술을 현실로 만드는 연구자,
박민선입니다.

#Computer Vision

#Deep learning

#Source-Free Domain Adaptation

#Test-Time Domain Adaptation

Contact

☎ 010-2769-4241 | ✉ pms01260@g.skku.edu



끈기로 AI 기술을 현실로 만드는 연구자, 박민선입니다

저는 라벨링이 없는 새로운 환경에서도
강건하게 작동하는 AI 기술을 개발합니다.
특히 도메인 변화에 능동적으로 적응할 수 있는
실용적인 AI 모델을 만드는 것을 목표로 합니다.

Education

- 2025.03 ~ 2027.02 성균관대학교 전자전기컴퓨터공학과 CGPA: 4.5 / 4.5
- 2021.03 ~ 2025.02 아주대학교 전자공학과 CGPA: 4.13 / 4.5

Publications

- 2026 Modality-Aware Cross-Modal Test-Time Adaptation for Compact Generative Vision-Language Models (Under-review) - 1저자
- 2025 Source Free Concept Bottleneck Model Adaptation With Confidence-Adaptive Conditional Ensemble (ICASSP 2026) - 1저자
- 2025 Enhancing Test-Time Training for Corruption Robustness in Image Classification (ICCE-Asia 2025) - 1저자
- 2025 Efficient Recurrent Optical Flow Refinement Using Mamba and Multi-Scale Loss (ITC-CSCC 2025) - 1저자
- 2024 폐 결절 검출을 위한 SAM 기반 데이터 증강 기법 (KCC 2024) - 1저자

Programming Skills

- Python (PyTorch, TensorFlow)
- C/C++

Award

- 2026.09 석사우수장학금 (이공계) 과기부 장관상
- 2024.12 아주대학교 전자공학과 산학박람회 대상
- 2023.02 혁신공유대학 가상환경 기반 자율주행 경진대회 모라이상

Scholarship

- 2024.09 원천장학
- 2024.03 유정장학
- 2023.09 김용득장학
- 2022.03 유정장학
- 2021.12 자기개발장학 AL (Active Learner)

Extracurricular Activities

- 2025 인공지능 챔피언 대회 예선 통과
- 2023 2023 데이터 크리에이터 캠프
- 2023 2023 소프트웨어야 놀자 대학생 멘토
- 2022 아주대학교 소학회 네트로닉스 시스템부 부장




Modality-Aware Cross-Modal Test-Time Adaptation for Compact Generative Vision-Language Models

Minseon Park, Jitae Shin[†] - Pre-print

Introduction



▲ Examples of corrupted image and corrupted text



▲ Visual question answering (VQA) accuracy drops for generative VLMs


- **Background** : 소형 시각-언어 모델 (VLM)은 실환경에서 흔히 발생하는 다중 모달 손상 (이미지 노이즈 및 질문 오타 동시 발생)에 매우 취약함.
- **Limitation** : 기존의 테스트 타임 적응 (TTA) 방법론은 주로 정해진 라벨 중 하나를 고르는 CLIP 형태의 판별 모델을 타겟함.
손상된 이미지-질문 쌍으로부터 개방형 답변을 생성해야 하는 VLM에는 기존 방식을 직접 적용하기 어려움 존재함.
- **Key contribution** : 이미지와 질문의 동시 손상에 실시간으로 적응하는 Modality-Aware Cross-Modal Test-Time Adaptation (MAC-TTA) 을 제안함.
 - ✓ 1. 소형 생성형 VLM의 다중 모달 손상 강건성을 평가하기 위한 최초의 벤치마크 (VQA-X-C, VQA-v2-C)를 제안함.
 - ✓ 2. 이미지 손상 (GrayAnchor)과 텍스트 손상 (CrossSpell)을 개별적으로 처리하면서 공유 백본으로 상호작용하는 테스트 타임 적응 기술을 제안함.
 - ✓ 3. 추가적인 데이터 라벨링이나 학습 데이터 없이도, 동시 손상 환경에서 단일 모달리티 성능 항상 폭의 합을 초과하는 큰 성능 개선을 달성함.



Modality-Aware Cross-Modal Test-Time Adaptation for Compact Generative Vision-Language Models

Minseon Park, Jitae Shin[†] - Pre-print

Method



● Gray Anchored Visual Adaptation

- Insight : 이미지가 손상될 경우 소형 VLM은 시각적 증거보다 모델 자체의 language prior에 의존하여 답변을 생성하는 문제가 발생함.
- Solution : 손상된 실제 이미지의 답변 예측 분포가 아무 정보가 없는 Gray anchor의 답변 예측 분포와 명확히 달라지도록 유도함.

$$\mathcal{L}_{GA} = \alpha H(p_t^{img}) - \lambda_{GA} JSD(p_t^{img}, sg(p_t^{gray}))$$

샘플마다 한 번의 확률적 SGD를 적용하여 시각 인코더의 LayerNorm 및 교차 모달 커넥터 파라미터만을 업데이트 함.

$$\psi_t = \psi_{t-1} - \eta \nabla_{\psi} \mathcal{L}_{GA}(\tilde{x}_t, \tilde{q}_t | \theta_{t-1})$$



Modality-Aware Cross-Modal Test-Time Adaptation for Compact Generative Vision-Language Models

Minseon Park, Jitae Shin[†] - Pre-print

Method

1. Corruption Detection

- ✓ 외부 영어 사전을 사용하여 입력된 질문 단어들을 검사함.
- ✓ 사전에 존재하지 않는 단어가 발견되면 손상된 단어로 식별함.

2. Corruption Detection


- ✓ C_{edit} : 외부 사전을 바탕으로 손상된 단어와 표기가 비슷해서 edit distance가 가까운 단어를 후보로 선택함.
- ✓ C_{vlm} : 적응된 VLM을 기반으로 현재 보고 있는 이미지와 앞서 등장한 질문을 바탕으로 시각적으로 타당성이 높은 후보를 추가함.

3. First Token Prefiltering

- ✓ 연산 비용을 줄이기 위한 효율화 단계.
- ✓ 생성된 모든 후보의 전체 확률을 일일이 계산하는 게 아닌, 첫번째 토큰 확률을 빠르게 확인하여 가장 가능성이 높은 상위 K 개의 후보만 남김.

4. Full Word Rescoring

- ✓ 최종 후보로 남은 K개의 단어에 대하여 full-word likelihood를 계산함.
- ✓ 여기에 해당 단어가 실제 언어에서 얼마나 자주 쓰이는지를 나타내는 frequency prior를 결합함.





Modality-Aware Cross-Modal Test-Time Adaptation for Compact Generative Vision-Language Models

Minseon Park, Jitae Shin[†] - Pre-print

Experiment

Main Results

Method	Clean	Image-C	Text-C	Both-C
<i>VQA-v2-C</i>				
Baseline [22]	88.33	78.09	72.04	40.90
MAC-TTA (ours)	89.33	79.66	81.62	58.68
<i>VQA-X-C</i>				
Baseline [22]	42.09	39.17	38.30	30.24
MAC-TTA (ours)	41.49	39.84	41.18	34.79

▲ Overall performance on VQA-v2-C and VQA-X-C (n=200). VQA-v2-C uses VQA accuracy in percent, and VQA-X-C uses ROUGE-L×100

Image Only Corruption

Method	Bright.	Contr.	Defocus	Elastic	Fog	Frost	Gauss.	Glass	Impulse	JPEG	Motion	Pixel.	Shot	Snow	Speckle	Zoom	Avg.
<i>VQA-v2-C</i>																	
Baseline [22]	90.33	74.33	78.67	74.00	82.50	82.67	72.17	90.17	73.50	82.33	77.50	72.17	75.83	79.17	79.00	65.17	78.09
DeYO [15]	91.00	73.33	80.83	76.00	83.33	83.67	72.50	91.00	73.00	83.17	79.83	73.33	76.67	79.17	80.00	68.17	79.06
MEMO [31]	89.83	73.83	78.50	75.00	82.50	83.17	73.17	90.00	73.33	82.33	78.83	73.67	74.83	79.17	79.00	64.33	78.22
GrayAnchor (ours)	91.83	75.00	81.67	76.33	84.33	83.67	74.50	91.17	72.67	83.83	79.17	74.00	77.33	81.00	82.17	68.33	79.81
MAC-TTA (ours)	91.33	74.67	81.67	76.33	83.83	83.17	74.50	91.17	72.33	84.33	79.17	74.00	77.33	80.50	81.83	68.33	79.66
<i>VQA-X-C</i>																	
Baseline [22]	41.41	39.63	39.67	38.50	40.36	40.04	37.77	40.40	37.83	41.81	38.64	38.65	38.61	39.37	39.61	34.48	39.17
DeYO [15]	41.18	38.72	38.75	38.94	41.02	39.59	38.68	40.82	37.12	41.86	36.17	39.42	35.95	39.03	35.73	35.05	38.63
MEMO [31]	41.46	39.16	39.49	38.53	40.67	40.37	37.15	40.58	37.58	41.58	38.29	38.63	38.39	39.31	39.72	36.40	39.21
GrayAnchor (ours)	41.03	39.65	38.94	38.65	40.41	40.65	38.26	40.51	37.86	42.32	39.16	38.41	38.57	39.74	40.10	36.79	39.44
MAC-TTA (ours)	40.82	38.59	40.02	40.16	40.88	40.31	39.02	41.18	40.21	40.95	40.67	37.00	39.72	39.73	40.80	37.41	39.84

▲ Image corruption results with clean text and corrupted image (n=200). Across Tables2-3, Best and second-best results are highlighted in skyblue and yellow

Ablation Study

Step	Added component	Score
<i>GrayAnchor</i>		
S0	No correction	28.78
S1	Entropy minimization only (TENT [29])	29.06
S2	+ JSD anchor regularization	30.03
<i>CrossSpell Components</i>		
S3	+ Corruption Detection & edit distance candidates	30.87
S4	+ Cross Modal Candidate Generation	33.15
S5	+ Full Word Rescoring	33.30
<i>Task dependent explanation decoding</i>		
S6	+ Answer conditioned MBR decoding	34.58

▲ Component wise additive ablation. Components are added sequentially on VQA-X-C under simultaneous corruption. Scores are ROUGE-L×100 with n=200.

Qualitative Results

Input	Baseline	MAC-TTA
Corrupted Image Corrupted Question Hawt soptr is this? Reference Answer tennis Gaussian noise + CharAug swap	Answer Vox Sports. Explanation The logo of Vox Sports is shown in the top right corner of the image.	Restored Question what sport is this? Answer Tennis. Explanation The person is holding a tennis racket. C_k Weight Hawt → what 96.4% what* 3.3% how 0.3% hart 0.3% soptr → sports 99.4% sports* 0.4% sorter 0.2% sop 0.2%
Corrupted Image Corrupted Question Is this a Begefarizn meZ.? Reference Answer no, yes Impulse noise + KeyboardAug	Answer No. Explanation The image has a plate of food and not a begefarizn meZ.	Restored Question Is this a vegetarian meal? Answer Yes. Explanation There is no meat on the plate. C_k Weight Begefarizn → vegetarian 99.1% vegetarian* 0.7% regularize 0.1% vegetarians 0.1% meZ.7 → meal 99.5% meal* 0.5% menu 0.1% me 0.1%

▲ Qualitative example under simultaneous image and question corruption.

Text Only Corruption

Method	KeyBd	Ocr	C-Del	C-Ins	C-Sub	C-Swap	rd	ri	rs	sr	BackTr	Formal	Casual	Passive	Active	Avg.
<i>VQA-v2-C</i>																
Baseline [22]	48.00	79.50	50.33	62.67	52.83	60.67	79.67	79.17	78.50	71.83	75.33	87.33	83.17	86.50	85.17	72.04
SymSpell [8]	48.33	77.50	49.33	77.50	56.67	63.00	79.67	79.17	78.50	71.33	77.33	88.83	81.17	87.33	86.17	73.46
NeuSpell [12]	49.50	85.83	48.67	59.17	50.67	68.17	78.83	75.67	79.67	69.00	74.50	87.50	83.17	86.67	84.83	72.12
CrossSpell (ours)	77.00	85.00	59.50	79.50	76.50	61.83	79.67	78.50	78.50	69.83	77.00	87.33	81.17	86.00	84.17	77.43
MAC-TTA (ours)	81.50	88.67	66.67	86.67	81.50	68.00	82.67	84.83	82.67	71.67	78.33	89.17	86.00	88.00	88.00	81.62
<i>VQA-X-C</i>																
Baseline [22]	32.66	39.63	34.29	35.66	33.71	36.03	41.09	39.06	38.15	36.75	40.72	42.33	41.46	40.49	42.49	38.30
SymSpell [8]	33.26	38.41	34.84	38.92	34.78	36.49	41.04	39.07	38.29	36.63	39.84	41.65	40.92	40.03	41.04	38.35
NeuSpell [12]	32.02	40.58	34.00	33.77	34.42	36.54	40.84	38.79	37.96	36.12	40.44	42.33	41.19	40.38	42.62	38.13
CrossSpell (ours)	38.62	40.20	36.92	41.20	39.63	37.39	41.13	39.19	38.12	36.66	41.59	42.54	41.41	40.29	42.38	39.82
MAC-TTA (ours)	41.16	41.35	38.78	41.92	40.14	37.98	41.61	42.90	41.21	39.57	41.02	43.20	41.44	42.23	43.18	41.18


▲ Text corruption results with clean text and corrupted image (n=200).

Source Free Concept Bottleneck Model Adaptation With Confidence-Adaptive Conditional Ensemble

Minseon Park, Jitae Shin[†] - 2026 IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP 2026)



Introduction




- **Background** : 기존 Concept Bottleneck Models (CBM)은 해석가능한 모델이지만, domain shifts에 취약하다는 한계가 존재함.
- **Limitation** : Source-Free Domain Adaptation (SFDA) 는 원본 데이터 없이 모델을 적응시킬 수 있는 기법임.
하지만 기존 SFDA 방식은 보통 분류 모델에 특화되어 있어, CBM의 '개념'을 이용한 2단계 구조에 적합하지 않음.
- **Key contribution** : 해석가능성을 유지하면서도 도메인 변화에 대한 견고성을 향상시키기 위해 C³BM(Concept bottleneck model with Confidence-adaptive Conditional ensemble) 제안함.
 - ✓ 1단계) Concept Layer 적응 : KL-Divergence와 Focal Loss를 결합한 hybrid distillation loss를 사용해 개념 계층을 적응함.
 - ✓ 2단계) Classifier 훈련 : 적응된 CBM과 VLM(Vision-Language Model)을 지능적으로 결합하는 conditional ensemble 교사를 사용함.
VLM은 confidence-adaptive gate를 통해 CBM의 예측이 불확실할 때만 개입하여 예측을 수정하는 corrective expert 역할을 수행함.

Source Free Concept Bottleneck Model Adaptation With Confidence-Adaptive Conditional Ensemble

Minseon Park, Jitae Shin[†] - 2026 IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP 2026)



Method



▲ The overall pipeline

● Phase 1 : Concept Adaptation

• 하이브리드 증류 손실

- ✓ 기존의 하드 타겟 기반 손실 대신, 개념의 의미적 온전성을 보존하기 위해 도입함.

$$\mathcal{L}_{distill} = \mathcal{L}_{kd} + \mathcal{L}_{focal}$$

• Soft Supervision (KL-Divergence)

- ✓ 개념 예측을 맞고 틀림이 아닌 확률값으로 다루어 유연하게 학습하도록 유도함.

$$\mathcal{L}_{kd} = \beta_{kld} T^2 \cdot [\text{KL}(\tilde{p}^{con} \parallel p_t^{con})]$$

• Hard-to-Adapt 개념 강조 (Focal Loss)

- ✓ 도메인 변화에 적응하기 어려운 개념에 모델이 더 집중하도록 유도함.

$$\mathcal{L}_{focal} = \beta_{focal} \cdot E_c[\text{FL}(p_{t,c})]$$

• 최종 개념 적응 목표식

$$\mathcal{L}_{concept} = \mathcal{L}_{distill} + \mathcal{L}_{Apt}$$




Source Free Concept Bottleneck Model Adaptation With Confidence-Adaptive Conditional Ensemble

Minseon Park, Jitae Shin[†] - 2026 IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP 2026)



Method



▲ The overall pipeline

● Phase 2 : Classifier Adaptation

• Confidence-Adaptive Conditional Ensemble

✓ 적응된 CBM과 제로샷 VLM을 동적으로 결합하여 교사 모델을 구성함.

• Measuring Adaptation Confidence

✓ 소스와 타겟 개념 로짓 간의 거리를 통해 개념 변화량을 측정.

$$d_i = \left\| \theta_{s,i}^{con} - \theta_{t,i}^{con} \right\|_2$$

• Adaptive Gating Mechanism

✓ CBM과 VLM의 예측이 다르고, VLM의 신뢰도가 동적 임계값을 넘을 때만 개입함.

$$\tilde{\theta}_i^{cls} = \begin{cases} \theta_{v,i}^{cls}, & \text{if } (\hat{y}_{t,i} \neq \hat{y}_{v,i}) \wedge (p_{v,i}^{max} > \tau_i) \\ \theta_{t,i}^{cls}, & \text{otherwise} \end{cases}$$

• Final Classifier Training

$$\mathcal{L}_{classify} = \mathcal{L}_{KD} + \mathcal{L}_{elastic}$$

Source Free Concept Bottleneck Model Adaptation With Confidence-Adaptive Conditional Ensemble

Minseon Park, Jitae Shin[†] - 2026 IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP 2026)



Experiment

- Comparison of our method against baselines

Dataset	Model			
	PCBM [15]	Label-free CBM [16]	CONDA [17]	C ³ BM
Waterbirds-shift	38.06 ± 4.33	32.38 ± 0.07	72.94 ± 0.92	76.61 ± 0.26
Waterbirds-orig	76.63 ± 1.98	85.02 ± 0.04	79.57 ± 0.79	88.06 ± 0.37
DF.h	93.36 ± 0.20	94.68 ± 0.00	89.00 ± 1.14	96.79 ± 0.02
KW-Bai	87.81 ± 0.18	89.20 ± 0.00	86.01 ± 0.63	90.49 ± 0.00
KWC-Bai	77.81 ± 0.75	81.25 ± 0.02	77.37 ± 1.47	83.44 ± 0.05

▲ Comparison of our method against baselines.
We report mean accuracy (%) ± std over 3 runs

- The sub-domains with the highest and lowest accuracy

Dataset	Model			
	PCBM [15]	Label-free CBM [16]	CONDA [17]	C ³ BM
DF.h (min)	83.48 ± 0.65	83.81 ± 0.03	79.79 ± 1.36	89.48 ± 0.14
DF.h (max)	98.88 ± 0.28	99.08 ± 0.02	94.42 ± 1.34	99.41 ± 0.01
KW-Bai (min)	79.05 ± 1.43	78.09 ± 0.08	76.15 ± 0.52	74.85 ± 0.39
KW-Bai (max)	95.05 ± 0.32	95.61 ± 0.01	93.18 ± 1.01	96.47 ± 0.09
KWC-Bai (min)	66.55 ± 2.52	68.83 ± 0.20	72.42 ± 3.22	72.66 ± 0.36
KWC-Bai (max)	85.00 ± 1.05	88.03 ± 0.05	83.67 ± 0.55	90.41 ± 0.06


▲ Mean accuracy (%) ± std over 3 runs on the sub-domains with the highest (max) and lowest (min) accuracy.

- Ablation Study

Phase	Method Configuration	Waterbirds	DF.h
—	Baseline	32.48	86.91
	+ ProDe (Original)	67.73	90.43
Phase 1	Baseline	32.48	86.91
	+ ProDe (w/o L_{Ref})	67.76	90.38
	+ $L_{distill}$	68.45	90.52
Phase 2	+ Ensemble	72.07	90.88
	+ Confidence	75.63	90.71
	+ KD (C³BM, Full)	76.39	92.08

▲ Ablation study on Waterbirds-shift and DF.h.
Com-ponents are added cumulatively.

- Analysis of Concept Adaptation




▲ Correcting a prediction via concept adaptation.

Enhancing Test-Time Training for Corruption Robustness in Image Classification

Minseon Park, Jungwoo Bae, Jitae Shin[†] - The 10th International Conference on Consumer Electronics Asia (ICCE-Asia 2025)

Introduction



▲ Test Time Training *



▲ Source Domain Image



▲ Target Domain Image


- **Background** : 기존 이미지 분류 모델은 데이터 분포의 작은 변화에도 성능이 크게 저하됨.
- **Limitation** : Test Time Training은 test 때 파라미터를 업데이트하지만, 사전 학습된 모델의 성능에 의존하고 테스트 데이터를 무작위로 처리할 경우 최적의 결과가 아닐 수 있음.
- **Key contribution** : 논문에서는 세가지 핵심 전략을 결합하여 성능을 향상시킨 TTT 프레임 워크를 제안함.
 - ✓ 모델 구조 개선 : non-causal 공간 특징을 효과적으로 처리하기 위한 bidirectional 및 gating 구조를 적용한 TTT 아키텍처를 사용함.
 - ✓ 훈련 단계 강화 : Mixup 증강을 사용하여 더욱 일반화되고 견고한 특징 표현을 학습함.
 - ✓ 테스트 단계 최적화 : 엔트로피 기반 샘플 순서 지정 전략을 도입하여 모델이 어려운 샘플부터 먼저 적응하도록 유도함.

* Sun, Yu, et al. "Learning to (learn at test time): Rnns with expressive hidden states." *arXiv preprint arXiv:2407.04620*(2024).


Enhancing Test-Time Training for Corruption Robustness in Image Classification

Minseon Park, Jungwoo Bae, Jitae Shin[†] - The 10th International Conference on Consumer Electronics Asia (ICCE-Asia 2025)

Method



- TTT Architecture for Image Classification
 - ✓ Bidirectional processing : 이미지의 공간적인 특징을 최대한 활용하기 위해, TTT를 양방향으로 적용함.
 - ✓ Gating : 사전 학습된 백본에 TTT의 기여도를 점진적으로 높여 모델의 안정성을 유지함.
- Robust Pretraining with Mixup Augmentation
 - ✓ 훈련 중 미니배치 내의 두 이미지를 섞어 새로운 이미지를 만들고, 라벨도 선형적으로 보간하여 사용함.
 - ✓ Mixup을 통해 학습된 견고한 특징 표현은 이후 테스트 단계에서 TTT가 더 효과적으로 적응할 수 있는 기반을 제공함.



- Entropy based Sample Ordering for TTT
 - ✓ 테스트 세트 전체에 대해 추론을 수행하여 각 샘플의 예측 분포에 대한 엔트로피를 계산함.
 - ✓ 계산된 엔트로피 값을 기준으로 샘플을 내림차순으로 정렬한 뒤 TTT를 적용함.
 - ✓ 'Hard-to-Easy' 접근법은 초기 단계에 가장 중요한 정보를 파악하도록 강제하여 적응 효율을 극대화 함.

▲ The overall pipeline of proposal method.

(a) Training Phase: A robust model is trained using Mixup augmentation.

(a) Test Phase: The model is first adapted on test samples sorted by predictive entropy, then used for final evaluation.

Enhancing Test-Time Training for Corruption Robustness in Image Classification

Minseon Park, Jungwoo Bae, Jitae Shin[†] - The 10th International Conference on Consumer Electronics Asia (ICCE-Asia 2025)

Experiment

- Comparison on various corruption types

Method	Corruption Type				
	gaussian noise	shot noise	impulse noise	defocus blur	glass blur
baseline	74.64	88.15	81.09	98.67	80.22
ours	79.90	90.73	79.22	98.92	79.35
baseline	motion blur	zoom blur	snow	frost	fog
	94.51	96.93	95.44	96.66	98.64
ours	95.37	97.64	96.02	97.22	98.99
baseline	brightness	contrast	elastic transform	pixelate	jpeg compression
	98.94	98.27	97.53	95.57	86.28
ours	99.12	98.70	97.94	95.91	87.83

▲ Performance comparison on 15 corruption types from CIFAR10-C

- Ablation study

TTT-IC	Ordering	Mixup	Passes	Accuracy (%)
✗	✗	✗	–	74.64
✓	✗	✗	1	78.44
✓	✗	✗	2	78.82
✓	✓	✗	2	79.00
✓	✓	✓	2	79.90


▲ Ablation study of the proposed components on CIFAR10-C gaussian noise. ‘Passes’ refers to the number of adaptation epochs over the entire test set




Efficient Recurrent Optical Flow Refinement Using Mamba and Multi-Scale Loss

Minseon Park, Jitae Shin[†] - The 42nd International Technical Conference on Circuits/Systems, Computers and Communications (ITC-CSCC 2025)

Introduction



▲ Optical flow 2D representation



▲ Flow map visualization


- **Background** : 광학 흐름 (Optical flow) 추정은 비디오 이해 및 자율 주행과 같은 컴퓨터 비전 작업에 필수적임.
- **Limitation** : RAFT나 FlowFormer와 같은 모델들은 ConvGRU를 기반으로 흐름 예측을 반복적으로 미세 조정함.
ConvGRU는 합성곱과 순환 연산을 반복 수행하여 파라미터 수가 많고 처리 속도가 상대적으로 느림.
- **Key contribution** : 논문에서는 정확도와 연산량을 동시에 고려한 효율적인 Optical flow 미세 조정 기법을 제안함.
 - ✓ 기존 ConvGRU를 Mamba 기반의 순환 미세 조정 모듈로 대체하여 예측 정확도와 신뢰성을 향상함.
 - ✓ low-resolution supervision을 포함하는 멀티 스케일 손실 구조를 도입하여 전역적인 모션 일관성 학습을 유도함.



Efficient Recurrent Optical Flow Refinement Using Mamba and Multi-Scale Loss

Minseon Park, Jitae Shin[†] - The 42nd International Technical Conference on Circuits/Systems, Computers and Communications (ITC-CSCC 2025)

Method



▲ The overall pipeline of proposal method

- Mamba-based Refinement with Positional Embedding
 - ✓ 반복적인 미세 조정 과정에서 기존 ConvGRU 모듈을 Mamba 구조로 대체함.
 - ✓ Mamba는 1차원 시퀀스를 입력으로 받으므로 cost features와 context feature을 공간 차원을 따라 평탄화 함.

$$\Delta f(x) = \text{Mamba} \left(\text{PE} \left(\text{Flatten}(\text{Concat}(c_x, q_x, t_x)) \right) \right)$$

- Multi-Scale Loss
 - ✓ 저해상도 예측값을 다운샘플링된 정답과 비교하는 추가적인 손실 항을 정의함.
- $$\mathcal{L}_{low}^{(i)} = \|f_{low}^{(i)} - f_{gt}^{\downarrow(i)}\|_1$$
- ✓ 최종 고해상도 예측의 품질 및 전역적인 모션 구조 학습 안정성을 향상시킴.

$$\mathcal{L}_{flow} = \sum_{i=1}^N \gamma^{N-i} \left[\lambda \cdot \mathcal{L}_{low}^{(i)} + \mathcal{L}_{high}^{(i)} \right]$$



Efficient Recurrent Optical Flow Refinement Using Mamba and Multi-Scale Loss

Minseon Park, Jitae Shin[†] - The 42nd International Technical Conference on Circuits/Systems, Computers and Communications (ITC-CSCC 2025)

Experiment

• Main Results

Methods	Evaluation Metrics	
	AEPE ↓	F1-All ↓
RAFT	36.85	85.58
FlowFormer	10.15	34.44
Proposed Method	9.56	29.82


▲ Quantitative results

• Ablation Study

Methods			Evaluation Metrics	
Mamba	PE	Multi-scale Loss	AEPE ↓	F1-All ↓
✓	✗	✗	9.80	30.81
✓	✓	✗	9.83	30.19
✓	✓	✓	9.56	29.82

▲ Ablation study on Mamba and Multi-scale Loss

• Qualitative Results



▲ Optical flow estimation

• Comparison of Model Parameters and FLOPs


Methods	Evaluation Metrics	
	Number of Parameter (M)	FLOPs (G)
FlowFormer	38.10	240.18
Proposed Method	25.66	185.22

▲ The number of decoder parameters was reduced by approximately 32.65%, and the overall FLOPs decreased by 22.88%

폐 결절 검출을 위한 SAM 기반 데이터 증강 기법

박민선, 최현진, 유동연, 선주성[†], 이정원[†] - 2024 한국컴퓨터종합학술대회 (KCC)

Introduction




▲ Sequence of Nodule Data Augmentation

- **Background** : 인공지능을 활용한 폐암 진단 보조 모델 연구가 활발히 진행되고 있음.
- **Limitation** : 개인정보 문제와 높은 레이블링 비용으로 인해 의료 데이터가 부족하여, 모델의 성능과 신뢰도를 저하시키는 주요 원인이 됨.
가짜 결절을 생성하는 증강 기법은 실제 존재하지 않는 질병 정보를 만들어낸다는 점에서 윤리적, 법적 한계를 지님.
- **Key contribution** : 실제 폐 결절을 정밀하게 추출한 뒤, 정상 X-ray 영상에 자연스럽게 합성하는 새로운 데이터 증강 기법을 제안함..
 - ✓ 일반 영상에 맞춰진 분할 모델 SAM을 형태와 밝기가 불규칙한 폐 결절 특성에 맞게 미세 조정함.
 - ✓ 제안된 기법으로 생성한 증강 데이터를 학습에 활용한 결과, 기존 대비 검출 모델의 민감도와 AUC가 크게 향상됨.

🔍 폐 결절 검출을 위한 SAM 기반 데이터 증강 기법

박민선, 최현진, 유동연, 선주성[†], 이정원[†] - 2024 한국컴퓨터종합학술대회 (KCC)

Method



▲ Sequence of SAM-based Data Augmentation Method

- 1단계: 결절 특화 분할 모델(SAM_N) 구축
 - ✓ 자체 보유한 결절 영역의 마스크로 기존 배포된 SAM 모델의 전체 가중치를 업데이트하는 방식의 Fine-tuning 절차를 거쳐 SAM_N을 구축함.
 - ✓ SAM_N 모델을 구축한 뒤, 폐 결절 이미지와 바운딩 박스 정보를 입력하여 결절의 영역을 추출함.
- 2단계: 정상 영상에 폐 결절 자연스럽게 합성
 - ✓ opencxr을 이용하여 폐 영역을 추출한 뒤 폐 안쪽 영역에 결절이 합성될 수 있도록 erosion 연산을 수행함.
 - ✓ SAM_N 모델로부터 추출된 결절은, 마스크에 Gaussian blur를 적용해서 자연스럽게 합성이 이루어지도록 함.




폐 결절 검출을 위한 SAM 기반 데이터 증강 기법


박민선, 최현진, 유동연, 선주성[†], 이정원[†] - 2024 한국컴퓨터종합학술대회 (KCC)

Experiment

결절 특화 분할 모델(SAM_N) 최적화




▲ Dice score & IoU score per epoch




▲ Dice score & IoU score per confidence score

YOLOv8을 이용한 증강 데이터 효율성 검증

PR - AUC (Precision Recall Area Under Curve)	Recall (FP per image = 1)	Recall (FP per image = 2)	Recall (FP per image = 5)
77.1% (+4.7%)	85.32% (+2.97%)	86.94% (+2.23%)	92.01% (+5.54%)



▲ PR curve (Recall / Precision)



▲ FROC curve (Recall / FP per image)

2025년 인공지능 챔피언 대회

DeepMood - 성균관대학교 미디어시스템 연구실 및 슈퍼인텔리전스 연구실 연합 (8인 / 팀원)

(2025.07 ~ 2025.09)

2024 아주대학교 전자공학과 산학박람회

개인

(2024.12.11 ~ 2024.12.13)

대상 수상

아주대학교 전자공학과 소학회 활동 - C언어 세미나

아주대학교 소학회 네트로닉스 시스템부 부장

(2022.03.18 ~ 2022.06.01)

2023 데이터 크리에이터 캠프

아주대학교 소학회 네트로닉스 (4인 1팀 / 팀원)

(2023.09.25 ~ 2023.11.03)

[네이버 커넥트재단] 2023 소프트웨어야 놀자 대학생 멘토

아주대학교 동아리 ATOM 2팀 (4인 / 팀원)

(2023.07.19 ~ 2023.08.31)

2022년 동계 혁신공유대학 가상환경 기반 자율주행 경진대회

아주대학교 소학회 네트로닉스 (4인 1팀 / 팀원)

(2023.01.02 ~ 2023.02.13)

모라이상 수상




2025년 인공지능 챔피언 대회 (2025.07 ~ 2025.09)

DeepMood - 성균관대학교 미디어시스템 연구실 및 수퍼인텔리전스 연구실 연합 (8인 / 팀원)

Overview

우울증 위험도 예측 AI 솔루션 시스템 구성도



- ✓ 망막 바이오마커를 정량적으로 분석함으로써, 비침습적이고 객관적인 우울증 조기경보 시스템을 실현하고자 함.
- ✓ 망막 이미지를 통해서 사용자로 하여금 부담 없이 본 솔루션을 통해서 AI 기반 우울증 중증도 진단 및 분석 레포트를 제공받을 수 있도록 함.
- ✓ 이를 통해 잠재적 환자 탐지 및 조기 치료에 기여를 최종 목표로 함.

Role

우울증 예측 모델 성능 개선

✓ 데이터 불균형 해소 및 학습 파이프라인 구축:

- 1) Focal Loss를 이용하여 어려운 샘플에 더 집중하게 하여 과적합을 완화함.
- 2) Label Smoothing을 이용한 결정 경계 완만화를 통해 일반화 능력을 개선함.
- 3) 데이터셋 불균형 상황에서의 Exponential Moving Average를 사용함.
- 4) 샘플 간 선형 보간을 이용해 데이터 다양성 증가를 통해 불균형 상황을 해소함.
- 5) Test-Time Training을 통한 조명, 기기에 대한 변동성을 테스트 시 미세 적응시켜 성능 저하를 방지함.

모델 성능 개선 결과

Model	Sensitivity (%)	Specificity (%)	AUC (%)	Accuracy (%)
ResNet18	59.09	66.46	60.75	66.21
ResNet50	45.45	67.87	58.97	67.12
ResNet101	22.73	93.42	55.31	91.06
ViT-B-16	22.73	94.20	57.20	91.82
SwinT	59.09	57.05	55.64	57.12
Dino (ViT-S-16)	40.91	76.80	57.52	75.61
Dino (ViT-B-16)	40.91	80.72	56.80	79.39
CoAtNet	63.64	62.23	62.73	62.27
Ours	54.55	80.88	69.52	80.00



2024 아주대학교 전자공학과 산학박람회 (2024.12.11 ~ 2024.12.13)


개인 참가

Background

- 연구 배경 및 문제 정의
 - ✓ 의료 이미지는 개인정보 보호 문제와 전문의 라벨링 비용으로 인해 대규모 확보가 매우 어려움.


Method

- 실제 결절 분할 및 자연스러운 합성
 - ✓ 실제 환자 이미지에서 결절 부분만 분할하여 정상 이미지에 합성하는 방식을 제안함.
 - ✓ 분할 모델인 SAM을 흉부 X-ray 영상 특성에 맞게 Fine-Tuning함.
 - ✓ 정상 이미지에서 폐 영역을 추출한 뒤, 결절 가장자리에 가우시안 블러링을 적용해 경계를 자연스럽게 합성하여 학습 데이터를 증강함.



▲ SAM 기반 결절 데이터 증강 기법


Experiment



▲ PR-Curve

▲ FROC-Curve

Presentation



- ✓ 문제 정의부터 결과 검증까지의 과정을 비전공 청중도 이해할 수 있도록 구성해 발표함.

Result

- ✓ 설득력을 인정받아 대상을 수여 받음.






2023 데이터 크리에이터 캠프 (2023.09.25 ~ 2023.11.03)

아주대학교 소학회 네트로닉스 (4인 / 팀원)

Overview


• 해결 과제



- ✓ 데이터 분석 강의와 멘토링으로 기초를 다진 뒤, 한식 이미지 42종을 ResNet18로 분류하는 과제를 수행함.
- ✓ 오분류 분석, 성능 개선, 건강식 13종 전 이학습까지 단계별 미션으로 구성됨.

Role

• 오분류 분석 기반 가설 수립




- ✓ 실패 샘플을 정성 분석해 색이 연하고 다채로운 이미지에서 오분류가 집중됨을 확인함.
- ✓ 1층 컨볼루션 필터의 RGB 가중치 분포를 함께 분석해, 모델이 형태보다 색 대비에 크게 의존한다는 가설을 세움.

• 가설 기반 타깃 증강 설계

- ✓ 무작위 증강 대신 색 의존성을 낮추는 방향으로 ColorJitter를 적용하고, hue 허용 범위를 검토해 음식 고유의 색이 왜곡되지 않는 수준으로 조정함.
- ✓ 회전과 반전을 더해 특정 위치와 방향에 대한 의존도 함께 완화함.

Reflections


- ✓ 멘토링을 통해 분석 결과를 근거로 개선 방향을 세우는 법을 배움.
- ✓ 여러 기법을 동시에 바꾸면 각 요인의 효과를 판단하기 어렵다는 점을 느끼며, 변인을 통제된 실험 설계의 중요성을 깨달음.



2022년 동계 혁신공유대학 가상환경 기반 자율주행 경진대회 (2023.01.02 ~ 2023.02.13)

아주대학교 소학회 네트로닉스 (4인 / 팀원)

Overview




주행순서 : 출발 => 미션1 => 미션2 => 미션3 => 미션4 => 미션5 => 미션1 => 미션2 => 도착
주행은 2차선 기준으로 주행하며 정적장애물에서만 차선변경 가능

대회 개요

- ✓ 대회의 목표는 가상 환경 Linux와 ROS의 운영체제를 이용하여, Morai Simulator에서 자율주행 자동차 미션을 수행하는 것임.
- ✓ 기본적인 주행, 랜덤하게 변하는 신호등 신호에 맞추는 미션, 동적 장애물을 피하는 미션, 정적 장애물을 피하는 미션, 차량 충돌 없이 로터리 통과 미션, 라바콘 장애물을 피하는 미션 등이 존재함.

Mission

Lane Detection




- ✓ windowsearch : gray scale로 변환된 카메라 영상에서 흰색 차선을 인식하는 함수를 구현함.

Interpolation을 이용한 mapping

- ✓ 대회의 코스대로 주행하기 위해 좌표값을 받아와서 현재 위치와(x, y) mapping한 값 중 가장 가까운 곳으로 이동하도록 제어함.


신호등 처리



- ✓ ROS Topic을 이용하여 모라이 시뮬레이터에서 publish하는 신호를 읽어오고 운행을 제어함.

Result

- ✓ 모라이상을 수상함.





아주대학교 전자공학과 소학회 활동 - C언어 세미나 (2022.03.18 ~ 2022.06.01)

아주대학교 소학회 네트로닉스 시스템부 부장


Description

• 활동 목적





- ✓ 신입생들은 프로그래밍 언어를 혼자 학습하는데 어려움을 겪을 거라고 생각하여 신입생들을 대상으로 C언어 세미나를 진행함.

• 수업 내용



- ✓ C 프로그램 기초, 자료형에서 시작해 형식지정자, 조건문, 함수, 배열, 포인터 순으로 주차를 배치함.
- ✓ 설명만으로는 개념이 잡히지 않을 것이라 판단해 주차마다 3~4개의 실습을 병행함.
- ✓ 학습 활동지를 제작해 제출된 답안을 직접 채점한 뒤 돌려주어 개별적으로 부족한 부분을 보완할 수 있도록 했음.



Reflections

- ✓ 학기 초 기본 문법도 낯설어 하던 부원들이 점점 스스로 코드를 완성해내는 모습을 보며 큰 보람을 느낀 활동이었음.
- ✓ 타인의 성장을 돕는 과정에서 스스로의 기본기도 다지고, 리더십의 중요성을 배울 수 있었음.



[네이버 커넥트재단] 2023 소프트웨어야 놀자 대학생 멘토 (2023.07.19 ~ 2023.08.31)

아주대학교 동아리 ATOM 2팀 (4인 / 팀원)

Description

수업 시연




- ✓ 초등학교 저학년 학생들이 쉽게 이해할 수 있도록 단어 선택에 신경을 쓰고, 초등학교생의 눈높이로 생각하려고 노력함.
- ✓ 학생들의 흥미를 유발하기 위해 45분 수업 시간 동안 개념 설명(10분) - 학습 활동(30분) - 요약 정리(5분)으로 설정함.

수업 내용



- ✓ 각각 4교시, 이틀에 걸쳐 실제 수업을 진행함.
- ✓ 초등학생들은 스크래치 등의 코딩 활동을 할 수 없기 때문에 '언플러그드 활동'으로 수업을 진행함.
- ✓ 대표적으로 글씨로 적힌 숫자 카드를 이용하여 숫자 인식 모델 학습시키기 와 윤리적인 인공지능을 그려보기 등이었음.
- ✓ 인공지능의 편향성과 악용가능성에 대해서도 설명하여 학생들에게 경각심을 일깨워주고자 함.

Reflections



- ✓ 초등학교 저학년 아이들을 수업에 따라오게 하도록 지도하는 데 많은 어려움이 있었으나, 설문조사를 할 때 수업이 매우 만족스러웠다는 아이들을 보니 뿌듯함을 느꼈음.
- ✓ 마지막 날에는 겨울방학에 또 와야 한다며 우는 아이도 있어서, 몽클했고 수업이 아이들에게 도움이 많이 된 것 같아서 기뻐함.

끝없는 도전을 통해 어제보다 오늘 더 성장하는 연구자가 되겠습니다.
감사합니다.

Contact

☎ 010-2769-4241 | ✉ pms01260@g.skku.edu